

AEC-128 곡선, 잔차가 되기까지 — 그리고 PCA와 1D-CNN이 그 잔차를 보는 방식

Stage-2 모델은 AEC-128 곡선을 그대로 쓰지 않는다. 임상 변수로 설명되는 부분을 먼저 빼서 **잔차(residual)**만 남긴 뒤, 그 잔차를 **PCA**로 요약하거나 **1D-CNN**에 직접 먹인다. 두 경로가 갈라지는 지점과, 각각 분류기에 최종적으로 들어가는 입력 벡터가 정확히 무엇인지를 정리한 문서.

[code/1_aec_residual_reclassify.py](#)

[code/3_aec_cnn_reclassify.py](#)

[docs/residual_reclassify_algorithm.md](#)

[docs/residual_reclassify_cnn_algorithm.md](#)

왜 곡선을 그대로 쓰지 않는가

AEC-128 곡선은 환자의 체질량(BMI)에 큰 영향을 받는다. BMI가 높을수록 곡선 자체가 체계적으로 기울어지는데, 이 기울어짐과 저-SMI 여부가 서로 얽혀 있어 곡선을 그대로 넣으면 **심슨의 역설(Simpson's paradox)**식 교란이 생긴다 — 실제로는 근육량과 무관한 "BMI 신호"를 모델이 "저-SMI 신호"로 착각해서 배울 위험이 있다는 뜻이다.

그래서 나이·키·몸무게·성별 4개 임상 변수로 곡선을 **먼저 예측**하고, 실측값 - 예측값인 **잔차**만 남긴다. 이 잔차는 "임상 변수로는 설명이 안 되는, 곡선에만 남아있는 순수한 정보"다. PCA와 CNN은 원본 곡선이 아니라 **바로 이 잔차**를 입력으로 받는다.

01 전처리 — 정규화 → 잔차화


잔차가 만들어지기까지 두 단계. 둘 다 내부 코호트(g1090)에서만 학습되고, 외부 코호트에는 고정된 파라미터로만 적용된다.

STEP 1 · 정규화

환자 평균으로 나누기

환자마다 노출선량 스케일이 달라 128-slice 곡선의 절대 크기가 제각각이다. 각 환자 곡선을 자기 자신의 평균으로 나눠 스케일 차이를 지우고, 곡선의 **형태**만 남긴다.

raw AEC (mAs, 환자별 스케일 상이)




```
norm[i] = raw[i] / mean(raw)
```

STEP 2 · 잔차화

임상 변수로 예측 후 빼기

표준화된 {나이, 키, 몸무게, 성별}로 128개 slice 값을 각각 선형회귀 예측한다. 실제 정규화 곡선에서 이 예측값을 뺀 것이 잔차 — PCA-CNN이 실제로 보는 신호다.

실측(회색) vs 임상변수 예측(점선) → 차이 음영이 잔차




```
resid[i] = norm[i] - LinearRegression(clinical)[i]
```

01b 교란이 실제로 사라지는가

BMI 중앙값 기준 Low / High 두 그룹의 평균 곡선을 잔차화 전·후로 겹쳐보면, 잔차화가 BMI 신호를 걷어내는 과정임을 바로 확인할 수 있다.


잔차화 전 — 정규화 곡선

두 그룹 평균이 체계적으로 벌어져 있다 (BMI 교란)



잔차화 후 — 잔차 곡선

그룹 평균이 0 근처로 모인다 (BMI로 설명되는 부분 제거됨)



02 잔차 이후, 두 경로로 갈라진다

128차원 잔차 곡선을 저차원 특징으로 요약하는 방식만 다를 뿐, 나머지 설계(내부 전용 학습, 외부 고정 적용, screen-positive만 대상)는 동일하다.



잔 차 곡 선 · 128차원 (resid[1..128])

■ 사람이 설계한 요약 — PCA

1_aec_residual_reclassify.py

내부 코호트 잔차 128차원에 PCA를 적용. 누적 설명분산 90%(또는 95%)에 도달하는 성분 수 k(최대 10개)만 남겨, 곡선의 형태 변이를 k개의 숫자로 압축한다.

누적 설명분산 & 성분 형태



STAGE-2 분류기 입력 벡터

임상변수 ×4 + PCA score ×k (k≤10) +
Stage-1 score ×1 (선택)


총 입력 차원 ≈ 4 + k (+1) → Logistic Regression / HistGradientBoosting

■ 모델이 직접 배우는 요약 — 1D-CNN

3_aec_cnn_reclassify.py

차원 축소를 사람이 정하는 대신, 잔차 128포인트를 slice별 평균/표준편차로 표준화한 뒤 그대로 CNN에 입력. conv 필터가 국소적인 곡선 형태를 스스로 찾아 10차원 임베딩으로 압축한다.

RESIDUALCNN 구조 (PARAMS ≈ 2,000)



STAGE-2 분류기 입력 벡터

곡선 임베딩 ×10 + 임상변수 ×4 +
Stage-1 score ×1 (선택)

곡선 임베딩(10) ⊕ side features → Linear(→10) → ReLU → Dropout → Linear(→1)

03 같은 잔차, 다른 요약 방식

두 경로가 무엇을 공유하고 무엇이 다른지 한눈에.

항목	PCA 경로	1D-CNN 경로
잔차 요약 주제	사람이 설계 (선형 직교 성분)	모델이 학습 (conv 필터)
요약 차원 결정	누적 설명분산 90/95% 기준, 최대 10	아키텍처로 고정 (GAP 출력 10차원)
요약 방식이 포착하는 것	곡선 전체의 전역 형태 변이 (저주파 위주)	곡선 국소 구간의 패턴 존재 여부
fold당 학습	1회 (단편 형태 해)	early-stopping epoch 탐색 → 5-seed 앙상블 재학습
과적합 방어	PCA 차원 제한 자체가 규제 역할	노이즈 augmentation, label smoothing, dropout 0.5, weight decay
내부 전용 적합 / 외부 고정 적용	공통 — 표준화·잔차화 회귀·요약 파라미터 모두 내부에서만 결정	
대상 환자	공통 — Stage-1 screen-positive만 (Stage-1 음성은 그대로 유지)	

04 결과: 특이도(Specificity) 개선폭

두 경로 모두 민감도 비열등성(97.5% CI 상한 ≤ 5%p 하락)을 통과하면서 특이도를 끌어올렸다 — 같은 internal(g1090, n=1090) / external(sdata, n=926) 코호트 기준.

경로	INTERNAL SPEC_DELTA	EXTERNAL SPEC_DELTA	판정
PCA	+0.043	+0.018	● PASS / PASS
1D-CNN	+0.052	+0.038	● PASS / PASS

CNN이 이 특정 split에서 더 큰 개선을 보였지만, screen-positive 학습셋이 작아(내부 약 560명·외부 약 415명) 시드 수 같은 학습 설정 하나만 바뀌어도 external spec_delta가 크게 흔들렸다 (튜닝 로그: +0.014 → +0.038, 3배 차이). "이번 조합에서 동등하거나 우수했다" 정도로 해석하는 것이 안전하다 — docs/residual_reclassify_cnn_algorithm.md §4.6/§6 참고.