

cluster_band는 알고리즘적으로 어떻게 8개 밴드를 정하는가

128개 AEC 슬라이스의 잔차 곡선을, 등간격이 아니라 "실제로 거동이 갈라지는 지점"에서 끊어 8개 구간으로 묶는 과정을 단계별로 뜯어본다. 아래 덴드로그램과 밴드 경계는 실제 internal 코호트(`g1090.xlsx`) 데이터로 계산한 결과다.

1 클러스터링 대상은 슬라이스다, 환자가 아니다

`resid` 는 (환자 수 × 128슬라이스) 잔차 행렬이다. `cluster_band` 는 이를 전치 (`resid.T`)해서 (128슬라이스 × 환자 수)로 바꾼 뒤 클러스터링한다. 즉 **한 슬라이스**가 클러스터링의 한 점(point)이 되고, 그 점의 좌표는 "이 슬라이스가 internal 환자 각각에서 가졌던 잔차값"이다. 두 슬라이스가 모든 환자에 걸쳐 비슷하게 오르내렸다면(=잔차 프로파일이 상관됨) 가까운 점으로 취급된다.




왼쪽: 환자 5명 × 슬라이스 8개(축약) 잔차 행렬. 오른쪽: 전치 후 슬라이스 8개 × 환자 5명 — 이제 각 행(슬라이스)이 "환자들에 대한 잔차 프로파일" 벡터가 되어, 이 행끼리 유사도를 비교한다.

2 인접 제약: 사슬(chain) 그래프

슬라이스끼리 아무렇게나 묶이면 "구간"이라는 개념이 깨진다. 그래서

`connectivity` 행렬로 슬라이스 `i` 는 `i-1`, `i+1` 과만 직접 연결되도록 강제한다

다 — 슬라이스 3번과 100번이 잔차 패턴이 비슷하다고 같은 밴드로 묶이는 일은 구조적으로 불가능하다. 아래는 실제 8-밴드 결과에서 3번째 밴드(슬라이스 51–64)와 4번째 밴드(슬라이스 65–81)가 갈라지는 경계 부근을 확대한 것이다.





연결선은 인접 슬라이스끼리만 존재 — 점선 부분이 Ward가 실제로 자른 경계(슬라이스 64 | 65). 64와 65는 연결 자체는 가능했지만, 병합 비용이 다른 인접 쌍보다 커서 마지막까지 합쳐지지 않았다.

3 Ward 연결법: 가장 싼 인접 병합부터

처음엔 슬라이스 128개가 각자 독립된 클러스터다. 이후 반복적으로, **인접한** 클러스터 쌍 중 병합했을 때 클러스터 내부 분산 증가량이 가장 작은 쌍을 하나씩 합친다. 이 증가량을 "병합 비용"이라 부른다.

- 1 128개 슬라이스를 각각 독립 클러스터로 시작한다.
- 2 사슬 그래프 상에서 **인접한** 클러스터 쌍만 후보로 본다.
- 3 후보 쌍 중 Ward 기준 병합 비용이 가장 작은 쌍을 하나 합친다.
- 4 클러스터 수가 8개가 될 때까지 2–3을 반복하고, 거기서 멈춘다.






실제 internal 잔차 데이터(128슬라이스)에 대해 계산한 전체 병합 트리(마지막 24개 병합만 표시). 세로축은 병합 비용(Ward 분산 증가량), 파란 점선은 `n_clusters=8`이 되는 지점의 절단선(cut) — 이 선 아래 남은 가지 수가 곧 최종 밴드 수다. 선을 더 내리면(비용 문턱을 낮추면) 밴드가 늘고, 올리면 줄어든다.

4 실제 결과: 128개 슬라이스 → 8개 밴드

절단 후 나온 8개 밴드를 슬라이스 순서대로 나열하면 폭이 전혀 균등하지 않다 — 가장 넓은 밴드(P1)는 30슬라이스, 가장 좁은 밴드(P8)는 9슬라이스다. 폭 차이 자체가 "어디서 곡선의 거동이 실제로 갈라지는지"를 반영한다.

cluster_band : 8 (데이터 기반 경계)

n = 128 slice



밴드	슬라이스 범위	폭
P1	1 - 30	30
P2	31 - 50	20
P3	51 - 64	14
P4	65 - 81	17
P5	82 - 96	15

밴드	슬라이스 범위	폭
■ P6	97 - 107	11
■ P7	108 - 119	12
■ P8	120 - 128	9

5 band:8 과의 차이

같은 8개로 나누는 `band` featurizer는 그냥 $128 \div 8 = 16$ 씩 등분한다. 아래에 나란히 놓으면, 데이터 기반 경계(위, 색으로 구분)가 등간격 경계(아래, 점선 테두리)와 슬라이스 51-81 구간에서 특히 크게 어긋나는 것을 볼 수 있다 — `band:8` 이라면 이 구간을 16/16으로 딱 갈랐겠지만, `cluster_band:8` 은 14/17로 비대칭하게 갈랐다.

cluster_band : 8 (색 = 데이터 기반 경계)

30 · 20 · 14 · 17 · 15 · 11 · 12 ·



band : 8 (점선 = 등간격 경계)

16 ×



이 프로젝트에서는 internal OOF 스왑 결과 튜닝된 `cluster_band:8` + `hgb` + stage-1 score 조합(max_depth=3, learning_rate=0.06은 둘 다 기본값, max_iter만 150→500으로 늘림)이 spec_delta +0.049로 476개 후보 중 1위였다. 이 그리드서치는 `cluster_band:8` 하나가 아니라 9개 curve_feat × logreg/hgb 하이퍼파라미터 전체로 넓혀 진행했는데도 상위 1-4위가 모두 `cluster_band:8` + `hgb`의 하이퍼파라미터 변형이었고(기본 하이퍼파라미터는 +0.036), 5위인 `pca:0.95` + `logreg` (+0.039)와는 확실한 격차를 두고 앞섰다. 그래서 최종 stage-2 모델로 선택됐다.

```
code/stage2_aec_residual_reclassify_bandfeat.py · fit_curve_featurizer(kind="cluster_band") ·  
AgglomerativeClustering(linkage="ward", connectivity=chain)
```