

HistGradientBoostingClassifier vs Logistic Regression — 결정경계는 실제로 어떻게 다른가

두 모델 다 stage-2 후보로 스웱에 들어가지만 작동 방식은 근본적으로 다르다. 아래는 실제 internal screen-positive 환자(n=563)의 두 실제 feature — stage-1 score와 `cluster_band`의 P5 밴드(슬라이스 82-96 평균 잔차) — 만 써서 두 모델을 직접 fit해 결정 경계를 그려본 것이다.

1 두 모델이 계산하는 것


둘 다 결국 "점수 → 확률"을 내놓지만, 그 점수를 만드는 방식이 다르다.

■ Logistic Regression

선형 결합 + 시그모이드

$$z = w_1x_1 + w_2x_2 + \dots + b$$

$$P(y=1) = \sigma(z) = 1 / (1+e^{-z})$$



feature 13개(clinical 4 + curve_feat + stage-1 score) 각각에 고정 가중치를 곱해 더하는 **단일 평면**. feature 간 상호작용은 사람이 교차항을 직접 만들어 넣지 않는 한 표현되지 않는다.

■ HistGradientBoostingClassifier

얇은 트리 150개를 순차적으로 더함

$$F_0 \bullet \text{ 초기 예측(로그오즈 기저값)}$$

$$+ \text{ } \text{lr} \times \text{tree}_1(x) \quad (\text{depth} \leq 3)$$

$$+ \text{ } \text{lr} \times \text{tree}_2(x) \quad (\text{이전 오차 보정})$$

$$\vdots$$

$$+ \text{ } \text{lr} \times \text{tree}_{150}(x)$$

`learning_rate=0.06` 만큼씩만 반영하며 150그루를 더해가는 구조라 **비선형·상호작용 패턴을 자동으로** 잡아낼 수 있지만, 표본이 적으면 (screen-positive n=563) 과적합 위험도 그만큼 커진다.

2 실제 데이터로 본 결정 경계


같은 563명, 같은 두 feature로 `LogisticRegression(C=1.0)` 과

`HistGradientBoostingClassifier(max_depth=3, learning_rate=0.06, max_iter=500)` 을 각각 fit했다(실제 최종 선택된 하이퍼파라미터와 동일 —

max_iter만 기본값 150에서 500으로 늘린 것). 배경 색은 각 모델이 내놓는 P(양성) 확률, 주황 점선은 0.5 결정 경계다.


■ Logistic Regression

직선(초평면) 하나로 나뉜다



■ HGB (500 iterations)

계단형 - 트리 분기 경계가 그대로 드러남




■ P(양성) 0 → 1 - - 0.5 결정 경계 ● 실제 양성 환자 ○ 실제 음성 환자

x축: stage-1 score(표준화 로짓, 클리닉 스크리닝 점수) · y축: cluster_band P5 (슬라이스 82-96 평균 잔차, 8개 밴드 중 y와 상관이 가장 큰 밴드). LogReg는 두 feature의 가중합이 임계값을 넘는지로만 가르기 때문에 경계가 항상 하나의 직선이다. HGB는 깊이 3인 트리들이 각 feature를 여러 번 나눠 잘라서, 경계가 축에 평행한 계단 모양으로 꺾인다 — "stage-1 score가 높으면서 동시에 P5도 특정 구간일 때만" 같은 국소적 패턴을 잡아낼 수 있다는 뜻이다.


3 부스팅이 반복될수록 경계가 어떻게 복잡해지는가

같은 HGB 모델을 `staged_predict_proba`로 중간 반복 시점(1, 20, 150, 500)에서 스냅샷을 찍었다. 트리가 1개일 때는 사실상 하나의 축-정렬 분할(단순 사각 경계)에 가깝고, 500개가 쌓이면서 점점 더 세밀한 계단 경계로 다듬어진다.



4 실제 스윕에서의 성능 차이

같은 `curve_feat` 조합에 logreg와 hgb(기본 하이퍼파라미터)를 둘 다 태운 7개 경우를 internal OOF spec_delta(특이도 개선폭) 기준으로 나란히 놓으면, hgb가 항상 이기는 게 아니라 `cluster_band:8`에서만 앞선다. `cluster_band:8` 그룹에는 별도로 그리드서치를 거쳐 찾은 튜닝 hgb(★ 표시) 막대도 함께 표시했다 — 이것이 476개 전체 후보 중 실제 최종 1위 값이다. 이 그리드서치는 `cluster_band:8` 한 곳에만 국한하지 않고 9개 `curve_feat` 조합 × logreg/hgb 하이퍼파라미터 전체로 넓혀 진행했지만, 최댓값은 여전히 `cluster_band:8 + hgb`에서 나왔다.



이 프로젝트의 최종 선택은 튜닝된 `cluster_band:8 + hgb`

(max_depth=3, learning_rate=0.06 — 둘 다 기본값 — max_iter만 150→500으로 늘림, spec_delta +0.049 — 위 그래프의 ★ 막대) — 기본 하이퍼파라미터의 `cluster_band:8 + hgb`는 +0.036에 그쳐 7쌍 비교에서는 1위였지만, 그 시점엔 2위인 `pca:0.95 + logreg` (+0.039)와 근접해 보였다. 9개 `curve_feat` 전체로 그리드서치를 넓혀보니 상위 1~4위가 모두 `cluster_band:8 + hgb`의 하이퍼파라미터 변형이었고, `max_iter`를 늘리는 것만으로 +0.049까지 올라가 `pca:0.95 + logreg`와의 격차가 오히려 더 벌어졌다. 나머지 6개 기본 쌍에서는 logreg가 같거나 더 나왔다.

```
code/stage2_aec_residual_reclassify_bandfeat.py · make_stage2_model() · LogisticRegression(C=1.0) vs  
HistGradientBoostingClassifier(max_depth=3, learning_rate=0.06, max_iter=150)
```